


COMPUTER VISION

컴퓨터 비전

기본 개념부터 최신 모바일 응용 예까지



6장. 특징 기술

PREVIEW

■ 앞 절에서 공부한 특징 검출 단계

- 예지 (3장), 지역 특징 (4장), 영역 (5장) → 매칭에 사용하기에 턱없이 빈약한 정보



(a) 관심점

그림 6-1 어떻게 기술할까?



(b) 영역



(c) 영상

■ 풍부한 정보를 어떻게 추출할까?

- 특징 기술 단계는 검출된 특징의 내부 또는 주위를 들여다 보고 풍부한 정보를 추출
- 특징의 성질을 기술(describe)해주므로 기술자(descriptor) 또는 여러 개의 값으로 구성된 벡터 형태이므로 특징 벡터(feature vector)라 부름

각 절에서 다루는 내용

1. 특징 기술자의 조건
2. 관심점(특징점)을 위한 기술자
3. 영역 기술자 : 5장에서 구한 영역에서 기술자를 추출하는 방법
4. 텍스쳐 : 텍스쳐 특징을 추출하는 기법
5. 주성분 분석 : 주성분 분석 기법의 원리와 알고리즘
6. 얼굴 인식 : 고유 얼굴

→ 주성분 분석을 이용한 얼굴 인식을 설명

6.1 특징 기술자의 조건

■ 특징 추출의 예

▪ 필기 숫자 인식

- 크기 정규화
- 이진화

00001100
00010000
00100000
01100000
11000110
11000011
11000001
11111110

특징
추출

방법 1 : 화소 각각이 특징 벡터

64 차원 특징 벡터

$$\mathbf{x}=(0,0,0,0,1,1,0,0,0,0,0,1,\dots,1,1,0)^T$$

방법 2 :

가로 세로 이등분

하여 검은 화소의
개수 비율이 특징
벡터

$$x_2=14/10$$

$$\frac{14}{10}$$

00001100

00010000

00100000

01100000

11000110

11000011

11000001

11111110

6
18

$$x_1=6/18$$

$$\mathbf{x}=(6/18,14/10)^T$$

또 다른 방법으로는?

6.1 특징 기술자의 조건

■ 특징 생성

- 외부의 물리적 패턴을 특징 벡터라는 수학적 표현으로 변환

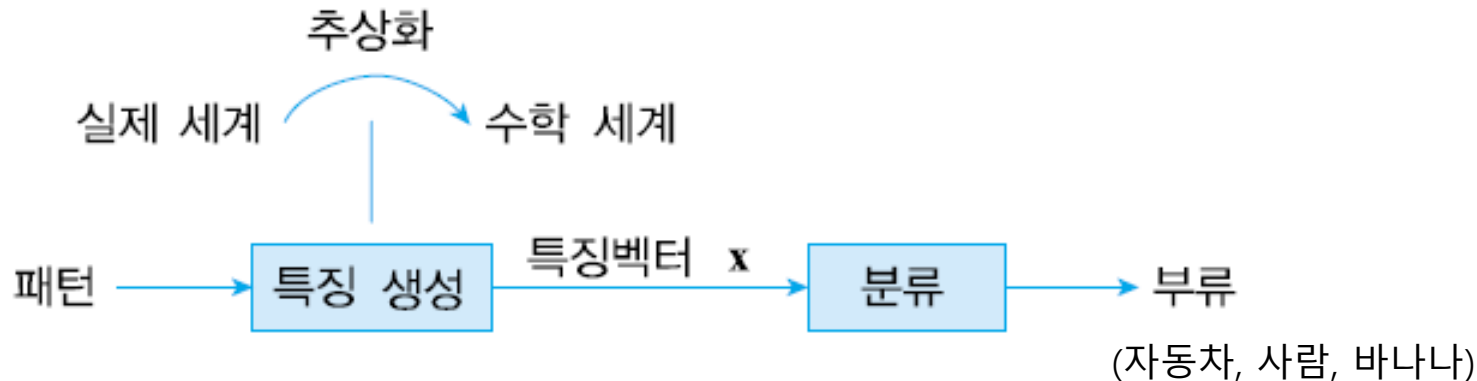


그림 8.1 패턴 인식의 일반적인 틀

■ 특징 생성 과정은 매우 다양

- 특징 추출은 외부 환경에 맞게 설계해야 하기 때문
 - 숫자와 한글은 다른 특징이 필요할 수 있음
 - 한글도 통째로 인식하는 방법과 자소로 분할한 후 인식하는 방법 등 다양
 - 정면 얼굴로 국한하는 하는 경우와 제약이 없는 얼굴 인식의 특징은 다를 수 있음

6.1 특징 기술자의 조건

■ 매칭이나 인식에 유용하기 위한 몇 가지 요구 조건

- 높은 분별력(discriminating power)
- 다양한 변환에 불변 (invariant)
 - 기하 불변성과 광도(photometric) 불변성
 - 변환에도 불구하고 같은(유사한) 값을 갖는 특징 벡터 추출해야 함




그림 6-2 다양한 변환

- 특징 벡터의 크기(차원)
 - 차원이 낮을수록 계산 빠름

■ 응용에 따라 공변(covariant)과 불변을 선택해야 함

6.2 관심점을 위한 기술자

■ 관심점을 어떻게 기술할 것인가?

- 윈도우의 크기가 중요
 - 스케일 정보 없는 관심점 (예, 해리스 코너)
 - 윈도우 크기를 결정하는데 쓸 정보가 없음
 - 스케일 불변성 불가능
 - 스케일 정보가 있는 관심점 (예, SIFT, SURF)
 - 스케일 σ 에 따라 윈도우 크기 결정
- 스케일 불변성 달성

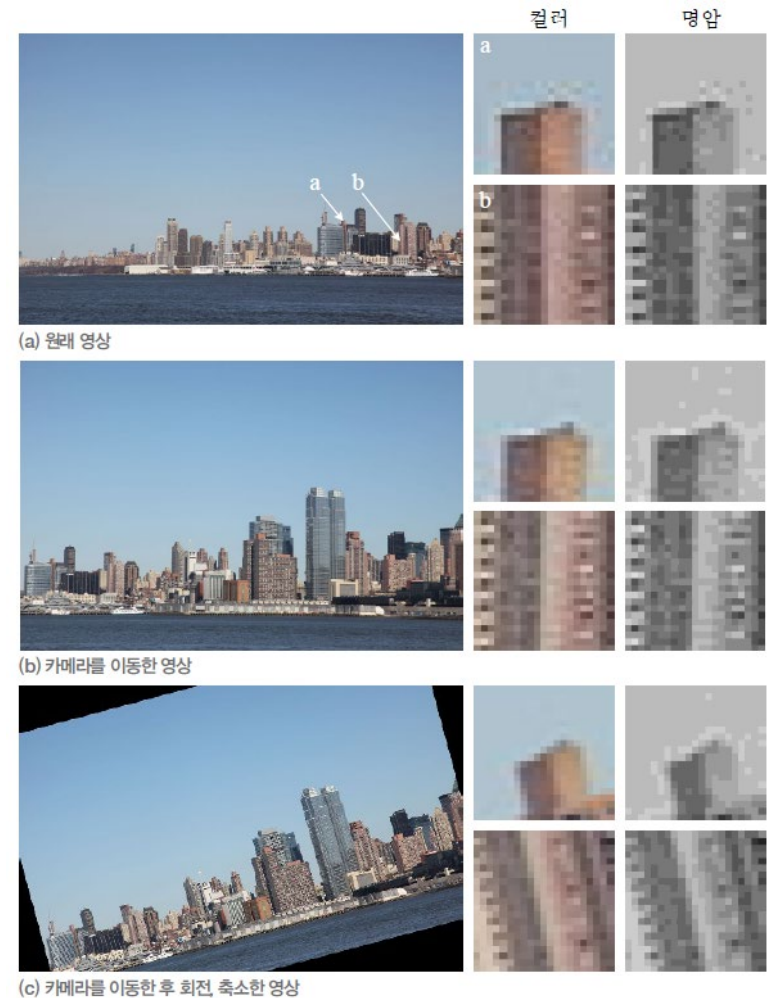


그림 6-3 관심점 주위에 대한 세밀한 관찰

6.2.1 SIFT 기술자

■ 4장에서 검출한 SIFT 키포인트(관심점)

- 검출된 옥타브 o , 옥타브 내의 스케일 σ_o , 그 옥타브 영상에서 위치 (r, c) 정보를 가짐

■ SIFT 기술자의 불변성

■ 스케일 불변 달성

- 윈도우를 옥타브 o , 스케일 σ_o 인 영상의 위치 (r, c) 에 씌움
- 윈도우 사이즈 : $(2w+1)*(2w+1)$ where $w=1.5*3*\sigma_o$

■ 회전 불변 달성

- 지배적인 방향 계산 : 윈도우 내의 그레이디언트 방향 히스토그램을 구한 후, 최대값을 갖는 방향 찾기
- 윈도우를 이 방향으로 씌움

■ 광도 불변 달성

- 특징 벡터 \mathbf{x} 를 $\|\mathbf{x}\|$ 로 나누어 정규화함

6.2.1 SIFT 기술자

■ SIFT 기술자 추출 알고리즘 [Lowe2004]

- 윈도우를 4*4의 16개의 블록으로 분할
 - 각 블록에서 그레이디언트 방향 히스토그램 구함
 - 그레이디언트 방향은 8개로 양자화
 - 그레이디언트의 크기를 가중치로 사용
- 4*4*8=128차원 특징 벡터 \mathbf{x}
- $\mathbf{x} / \|\mathbf{x}\|$: 정규화, 광도 불변성을 위해 단위벡터로 변환




그림 6-4 SIFT 기술자 추출을 위한 좌표계와 4×4 블록

알고리즘 6-1 SIFT 기술자 추출

입력 : 입력 영상 f 에서 검출된 키포인트 집합 $p_i = (y_i, x_i, \sigma_i)$, $1 \leq i \leq n$ // 4.4.3절의 알고리즘으로 추출

출력 : 기술자가 추가된 키포인트 집합 $p_i = (y_i, x_i, \sigma_i, \theta_i, \mathbf{x}_i)$, $1 \leq i \leq m$

```
1  for( $i=1$  to  $n$ ) {  
2     $p_i$ 의 지배적인 방향  $\theta_i$ 를 계산한다. // 이때 하나의 키포인트가 여러 개로 나뉠 수 있음  
3     $p_i$ 의 특징 벡터  $\mathbf{x}_i$ 를 계산한다.  
4     $\mathbf{x}_i$ 를 정규화한다.  
5  }
```

6.2.2 SIFT의 변형

■ PCA-SIFT [Ke2004]


- 키포인트에 39×39 윈도우 씌우고 도함수 d_y 와 d_x 계산
- $39 \times 39 \times 2 (=3,042)$ 차원의 벡터를 PCA를 이용하여 20차원으로 축소

■ GLOH [Mikolajczyk2005a]


- 원형 윈도우로 17개 영역 각각에서 16단계의 그레이디언트 방향 히스토그램을 계산
- $17 \times 16 (=272)$ 차원의 벡터를 추출하고, PCA를 이용하여 128차원으로 축소

■ 모양 콘텍스트 [Mikolajczyk2005a]

- 원형 윈도우로 36차원 특징 벡터 추출



(a) GLOH




(b) 모양 콘텍스트

그림 6-5 GLOH와 모양 콘텍스트가 사용하는 원형 윈도우

6.2.2 Histogram of Oriented Gradient(HOG)

- 영상을 일정 크기의 셀로 분할
- 각 셀마다 픽셀의 **gradient**를 구해서 **Histogram**으로 표현한 벡터
- 왜곡이 적은 물체 식별에 적합



6.2.3 이진 기술자

■ 빠른 매칭을 위해 특징 벡터를 이진열로 표현

- 비교 쌍의 대소 관계에 따라 0 또는 1
- 비교 쌍을 구성하는 방식에 따라 여러 변형




그림 6-6 이진 기술자의 조사 패턴


- 매칭은 **해밍 거리**를 이용하여 빠르게 수행
- 해밍 거리 : 같은 비트 수를 갖는 **2진** 부호 사이에 대응되는 비트값이 일치하지 않는 개수
- 1**1**00010**0**과 1**0**00010**1**은 해밍 거리 2

6.2.3 이진 기술자


■ BRIEF, ORB, BRISK

표 6-1 이진 기술자의 특성 비교


| | 스케일 불변 | 회전 불변 | 특징 벡터 비트 수 |
|-------|--------|-------|------------|
| BRIEF | X | X | 256비트 |
| ORB | X | O | 512비트 |
| BRISK | O | O | 512비트 |



(a) BRIEF



(b) ORB



(c) BRISK

그림 6-7 세 가지 이진 기술자가 사용하는 조사 패턴

6.3 영역 기술자


■ 영역의 표현

| | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| 0 | | | | | | 2 |
| 1 | | | | | 4 | 2 |
| 2 | 2 | | | | 4 | 3 |
| 3 | 2 | 3 | 3 | 3 | 3 | 4 |
| 4 | 3 | 3 | 3 | 4 | 4 | |
| 5 | | 2 | 3 | 4 | | |

(a) 명암 영역

| | 0 | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|---|
| 0 | | | | | | 1 |
| 1 | | | | | 1 | 1 |
| 2 | 1 | | | | 1 | 1 |
| 3 | 1 | 1 | 1 | 1 | 1 | 1 |
| 4 | 1 | 1 | 1 | 1 | 1 | |
| 5 | | 1 | 1 | 1 | | |

(b) 이진 영역



시작점 : $C=(4,0)$

체인 코드 : 2270012166655443

(c) 체인 코드 표현

그림 6-8 영역의 표현

6.3.1 모멘트

6.3.2 모양

6.3.3 푸리에 기술자

6.3.1 모멘트

- 이진 영역의 모멘트 – 픽셀의 위치 정보만으로 추출
- $(q + p)$ 차 모멘트
 - 물리에서 힘을 측정하는데 쓰는 모멘트를 영상에서 특징을 추출하는 데 적용

$$m_{qp} = \sum_{(y,x) \in R} y^q x^p \quad (6.1)$$

$$\text{면적 } a = m_{00} \quad \text{중점 } (\bar{y}, \bar{x}) = \left(\frac{m_{10}}{a}, \frac{m_{01}}{a} \right)$$

- 중심 모멘트

$$\mu_{qp} = \sum_{(y,x) \in R} (y - \bar{y})^q (x - \bar{x})^p \quad (6.4)$$

$$\text{열 분산 } v_{cc} = \frac{\mu_{20}}{a} \quad \text{행 분산 } v_{rr} = \frac{\mu_{02}}{a} \quad \text{혼합 분산 } v_{rc} = \frac{\mu_{11}}{a}$$

열 분산 : 화소들이 열(수직) 방향으로 얼마나 넓게 퍼져있는지

6.3.1 모멘트

■ 크기(스케일) 불변 모멘트

$$\eta_{qp} = \frac{\mu_{qp}}{\mu_{00}^{\left(\frac{q+p}{2}+1\right)}} \quad (6.8)$$

■ 회전 불변 모멘트 [Hu62]

$$\begin{aligned} \phi_1 &= \eta_{20} + \eta_{02} \\ \phi_2 &= (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\ \phi_3 &= (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \\ \phi_4 &= (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2 \\ \phi_5 &= (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ &\quad (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \\ \phi_6 &= (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03}) \\ \phi_7 &= (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] + \\ &\quad (3\eta_{12} - \eta_{30})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \end{aligned} \quad (6.9)$$

6.3.1 모멘트

■ 명암 영역의 모멘트 - 픽셀 값을 이용

$$m_{qp} = \sum_{(y,x) \in R} y^q x^p f(y, x) \quad (6.10)$$

$$\text{중점 } (\bar{y}, \bar{x}) = \left(\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}} \right) \quad (6.11)$$

$$\mu_{qp} = \sum_{(y,x) \in R} (y - \bar{y})^q (x - \bar{x})^p f(y, x) \quad (6.12)$$

- 식 (6.8)의 크기 불변과 식 (6.9)의 회전 불변한 모멘트는 동일하게 정의됨

6.3.2 모양

■ 여러 가지 모양 특징

$$\text{면적 } a = \sum_{(y,x) \in R} 1$$

$$\text{둘레 } p = n_{\text{even}} + n_{\text{odd}} \sqrt{2}$$

이때 n_{even} = 짝수 체인의 개수

체인 코드의 여덟 방향 중에서 n_{odd} = 홀수 체인의 개수




그림 6-9 이웃 화소까지의 거리

$$\text{둥근 정도 } r = \frac{4\pi a}{p^2}$$

길쭉한 정도 $e = \frac{a}{w^2}$ w : 영역이 소멸될 때까지 침식 연산을 반복해서 그 반복회수의 2배

$$\text{주축의 방향 } \theta = \frac{1}{2} \arctan \left(\frac{2\mu_{11}}{\mu_{20} - \mu_{02}} \right)$$

6.3.2 모양

예제 6-1 특징 기술자 추출

| | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 0 | 1 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | | | | | | 1 | | | | | | |
| 1 | | | | | 1 | 1 | | | | | | |
| 2 | 1 | | | | 1 | 1 | | | | 3 | 3 | |
| 3 | 1 | 1 | 1 | 1 | 1 | 1 | | | | 3 | 3 | |
| 4 | 1 | 1 | 1 | 1 | 1 | | | | | 3 | 3 | |
| 5 | | 1 | 1 | 1 | | | | | | 3 | 3 | |
| 6 | | | | | | | | | | 3 | 3 | |
| 7 | | | | | 2 | 2 | | | | 3 | 3 | |
| 8 | | | | 2 | 2 | 2 | 2 | | | 3 | 3 | |
| 9 | | | | 2 | 2 | 2 | 2 | | | 3 | 3 | |
| 0 | | | | | 2 | 2 | | | | 3 | 3 | |
| 1 | | | | | | | | | | | | |

그림 6-10 세 개의 영역

영역1의 특징 기술자

- 면적 $a = 20$
- 중점 $(\bar{y}, \bar{x}) = \left(\frac{1}{20} \sum_{(y,x) \in R} y, \frac{1}{20} \sum_{(y,x) \in R} x \right) = (3.05, 2.7)$
- 행 분산 $v_{rr} = \frac{1}{20} \sum_{(y,x) \in R} (x - 2.7)^2 = 3.01$
- 열 분산 $v_{cc} = \frac{1}{20} \sum_{(y,x) \in R} (y - 3.05)^2 = 1.848$
- 혼합 분산 $v_{rc} = \frac{1}{20} \sum_{(y,x) \in R} (y - 3.05)(x - 2.7) = -1.135$
- 둘레 $p = 10 + 6\sqrt{2} = 18.485$
- 둥근 정도 $r = \frac{4\pi \times 20}{18.485^2} = 0.736$

| | 면적 a | 중점 (\bar{y}, \bar{x}) | 행 분산 v_{rr} | 열 분산 v_{cc} | 혼합 분산 v_{rc} | 둘레 p | 둥근 정도 r |
|-----|-----------|----------------------------|------------------|------------------|-------------------|-----------|--------------|
| 영역1 | 20 | (2.7, 3.05) | 3.01 | 1.848 | -1.135 | 18.485 | 0.736 |
| 영역2 | 12 | (4.5, 8.5) | 0.917 | 0.917 | 0.0 | 9.657 | 1.617 |
| 영역3 | 18 | (9.5, 6) | 0.25 | 6.667 | 0.0 | 18 | 0.698 |

6.3.2 모양

■ 투영

$$\begin{aligned} \text{행 투영 } h_j &= \text{행 } j \text{에 있는 1의 개수, } 0 \leq j \leq M-1 \\ \text{열 투영 } v_i &= \text{열 } i \text{에 있는 1의 개수, } 0 \leq i \leq N-1 \end{aligned} \quad (6.18)$$

| | 0 | 1 | 2 | 3 | 4 | 5 | |
|---|---|---|---|---|---|---|---|
| 0 | | | | | | 1 | 1 |
| 1 | | | | | 1 | 1 | 2 |
| 2 | 1 | | | | 1 | 1 | 3 |
| 3 | 1 | 1 | 1 | 1 | 1 | 1 | 6 |
| 4 | 1 | 1 | 1 | 1 | 1 | | 5 |
| 5 | | 1 | 1 | 1 | | | 3 |
| | 3 | 3 | 3 | 3 | 4 | 4 | |

열 투영

특징 벡터 $\mathbf{x}=(1,2,3,6,5,3,4,4,3,3,3,3)$

이웃한 2개의 투영을 평균해서
차원을 반으로 줄이면 $\mathbf{x}=(1.5,4.5,4,4,3,3)$

그림 6-11 투영 특징

6.3.2 모양

■ 프로파일

상 프로파일 t_i = 위에서 열 i 를 바라보았을 때 처음 1까지의 거리, $0 \leq i \leq N-1$

하 프로파일 b_i = 아래에서 열 i 를 바라보았을 때 처음 1까지의 거리, $0 \leq i \leq N-1$

좌 프로파일 l_j = 왼쪽에서 행 j 를 바라보았을 때 처음 1까지의 거리, $0 \leq j \leq M-1$

우 프로파일 r_j = 오른쪽에서 행 j 를 바라보았을 때 처음 1까지의 거리, $0 \leq j \leq M-1$

(6.19)

| | | | | | | | | | |
|-----------|---|-------------|---|---|---|---|-----|---|-----------|
| | | 상 프로파일 | | | | | | | |
| | | 2 3 3 3 1 0 | | | | | | | |
| 좌 프로파일 | 5 | | | | | | 1 | 0 | 우 프로파일 |
| | 4 | | | | | | 1 1 | 0 | |
| | 0 | 1 | | | | | 1 1 | 0 | |
| | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 0 | |
| | 0 | 1 | 1 | 1 | 1 | 1 | | 1 | |
| | 1 | | 1 | 1 | 1 | | | 2 | |
| | | 하 프로파일 | | | | | | | |
| | | 1 0 0 0 1 2 | | | | | | | |

특징 벡터 $\mathbf{x}=(2,3,3,3,1,0,0,0,0,0,1,2,2,1,0,0,0,1,1,0,0,0,4,5)$

이웃한 3개의 값을 평균해서 차원을 줄이면

$\mathbf{x}=(2.66,1.33,0,1,1,0.33,0.33,3)$

그림 6-12 프로파일 특징

6.3.3 푸리에 기술자

[그림 6-13]에서 입력 신호 (a)와 (b)의 파형을 살펴보자. 두 신호는 크게 다르다. 앞의 신호 $s_1(x)$ 는 뒤의 것 $s_2(x)$ 에 비해 변화가 빠르다. 이러한 성질을 적절히 수량화하면 두 신호를 분류하는데 쓸모 있는 특징을 얻을 수 있다. 이러한 성질을 어떻게 수량화할 수 있을까?

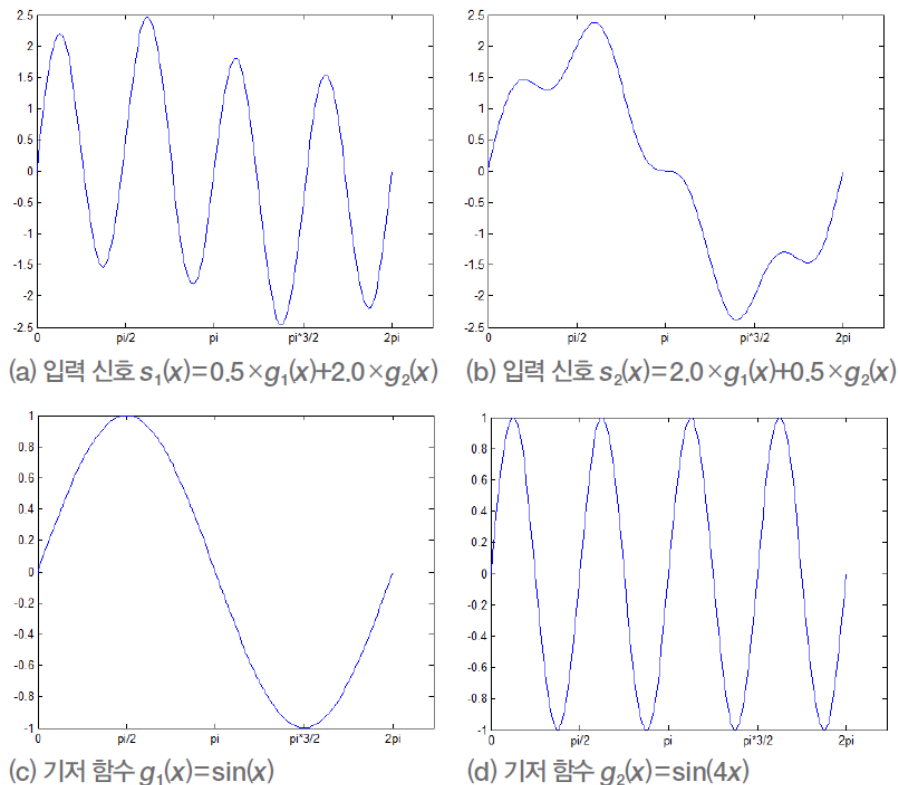



그림 6-13 입력 신호를 기저 함수의 선형 결합으로 표현

6.3.3 Fourier Series - 주기신호


$$x(t) = \sum_{k=-\infty}^{\infty} a_k e^{j2\pi k f_0 t} \quad a_k = \frac{1}{T_0} \int_0^{T_0} x(t) e^{-j(2\pi k / T_0)t} dt$$



6.3.3 Fourier Transform - 비주기신호

$$x(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} X(\omega) \exp[j\omega t] d\omega$$

$$X(\omega) = \int_{-\infty}^{\infty} x(t) \exp[-j\omega t] dt$$



6.3.3 푸리에 기술자

- 신호를 기저 함수(basic function)의 선형 결합(linear combination)으로 표현

$$s_1(x) = 0.5g_1(x) + 2.0g_2(x)$$

$$s_2(x) = 2.0g_1(x) + 0.5g_2(x)$$

- 두 신호의 계수 (0.5, 2.0)과 (2.0, 0.5)는 둘을 구별해주는 좋은 특징 벡터

- 신호가 입력되면 어떻게 계수를 알아낼 것인가?

- 푸리에 변환으로 가능
 - $t(\cdot)$ 가 계수에 해당
 - i 축 : 공간 도메인, u 축 : 주파수 도메인

$$t(u) = \frac{1}{\sqrt{n}} \sum_{i=0}^{n-1} s(i) \exp\left(-j \frac{2\pi ui}{n}\right), \quad 0 \leq u \leq n-1$$

이때 $s(0), s(1), \dots, s(n-1)$ 은 입력 이산 신호

(6.20)

6.3.3 푸리에 기술자

■ 영역에 푸리에 변환을 어떻게 적용하나?

- 영역을 경계 표현으로 바꾼 뒤, 점의 위치를 복소수로 표현하면 푸리에 변환 식에 대입 가능

• [그림 6-8]에 있는 영역의 경계 표현:

$(4,0)-(3,0)-(2,0)-(3,1)-(3,2)-(3,3)-(2,4)-(1,4)-(0,5)-(1,5)-(2,5)-(3,5)-(4,4)-(5,3)-(5,2)-(5,1)$

$$s(i) = y_i + j x_i, \quad 0 \leq i \leq n-1 \quad (6.21)$$

알고리즘 6-2 푸리에 기술자 추출

입력 : 영역 R , 필요한 특징 개수 $2d$

출력 : $2d$ 차원의 기술자(특징 벡터) \mathbf{x}

- 1 영역 R 을 식 (6.21)과 같은 형태로 변환한다.
- 2 식 (6.20)을 이용하여 푸리에 변환을 구한다. // 빠른 계산을 위해 FFT를 사용한다.
- 3 $\mathbf{x} = (\text{real}(t(0)), \text{imag}(t(0)), \dots, \text{real}(t(d-1)), \text{imag}(t(d-1)))$;

6.4 텍스처(Texture)

■ 텍스처란?

- 일정한 패턴의 반복
- 구조적 방법(structural method)과 통계적 방법(statistical method)
- 구조적 방법 – 기본 요소(텍셀, texel)를 추출한 후, 텍셀의 공간적인 배열을 찾음



그림 6-14 텍스처



텍셀 : 꽃, 추출에 어려움

6.4.1 전역 기술자

6.4.2 지역 관계 기술자

6.4.1 전역 기술자

■ 에지 기반

$$T_{edge} = (busy, mag(i), dir(j)), \quad 0 \leq i \leq q-1, \quad 0 \leq j \leq 7$$

(6.23)

이때 $busy = \frac{\text{영역의 에지 화소 수}}{\text{영역의 화소 수}}$

$mag(i)$: 에지 화소의 에지 강도를 q 단계로 양자화하여 구한 히스토그램

$dir(i)$: 8 방향으로 양자화된 에지 방향 히스토그램

■ 명암 히스토그램 기반

$$\mu_r = \sum_{l=0}^{L-1} (l-m)^r \hat{h}(l) \quad T_{histogram} = (smooth, skew, uniform, entropy)$$

영역의 부드러운 정도

이때 $smooth = 1 - \frac{1}{1 + \frac{\mu_2}{(L-1)^2}}$

히스토그램이 밝은 쪽과 어두운 쪽 중 어느 쪽에 치우쳤는 지

$skew = \mu_3$

영역이 얼마나 균일한 지

$uniform = \sum_{l=0}^{L-1} \hat{h}(l)^2$

무질서도 :

$entropy = - \sum_{l=0}^{L-1} \hat{h}(l) \log_2 \hat{h}(l)$

영역이 얼마나 변화가 심한 지

$$h(l) = |\{(j,i) | f(j,i) = l\}|$$

$$\hat{h}(l) = \frac{h(l)}{M \times N}$$

6.4.1 전역 기술자

■ 한계

- 지역적인 정보 반영하지 못함




그림 6-15 전역 텍스처 기술자는 이들을 구별하지 못한다.

6.4.2 지역 관계 기술자

■ 원리

- 화소 사이의 이웃 관계를 규정하고, 그들이 형성하는 패턴을 표현

■ 동시 발생 행렬 (co-occurrence matrix)

- 이웃 관계를 이루는 화소 쌍의 명암이 (j, i) 인 빈도수 세어, 행렬 O 의 요소 o_{ji} 에 기록



그림 6-16 동시 발생 행렬(이웃 관계는 '바로 오른쪽 이웃')

6.4.2 지역 관계 기술자

■ 동시 발생 행렬에서 특징 추출

$$\hat{O}_{ji} = \frac{O_{ji}}{n} \quad (6.26)$$

$$\text{균일성(에너지) } energy = \sum_{j=0}^{q-1} \sum_{i=0}^{q-1} \hat{O}_{ji}^2 \quad (6.27)$$

$$\text{엔트로피 } entropy = - \sum_{j=0}^{q-1} \sum_{i=0}^{q-1} \hat{O}_{ji} \log_2 \hat{O}_{ji} \quad (6.28)$$

$$\text{대비 } contrast = \sum_{j=0}^{q-1} \sum_{i=0}^{q-1} (j-i)^2 \hat{O}_{ji} \quad (6.29)$$

$$\text{동질성 } homogeneity = \sum_{j=0}^{q-1} \sum_{i=0}^{q-1} \frac{\hat{O}_{ji}}{1 + |j-i|} \quad (6.30)$$

$$\text{공관계 } correlation = \sum_{j=0}^{q-1} \sum_{i=0}^{q-1} \frac{(j - \mu_r)(i - \mu_c) \hat{O}_{ji}}{\sigma_j \sigma_i}$$

$$\text{이때 } \mu_r = \sum_{j=0, q-1} j \sum_{i=0, q-1} \hat{O}_{ji}, \quad \mu_c = \sum_{i=0, q-1} i \sum_{j=0, q-1} \hat{O}_{ji} \quad (6.31)$$

$$\sigma_r^2 = \sum_{j=0, q-1} (j - \mu_c)^2 \sum_{i=0, q-1} \hat{O}_{ji}, \quad \sigma_c^2 = \sum_{i=0, q-1} (i - \mu_r)^2 \sum_{j=0, q-1} \hat{O}_{ji}$$

6.4.2 지역 관계 기술자

■ 지역 이진 패턴 (LBP, Local Binary Pattern) [Ojala96]

- 8개 이웃과 대소관계에 따라 이진열을 만든 후 [0, 255] 사이의 십진수로 변환
- 모든 화소를 가지고 히스토그램 구성

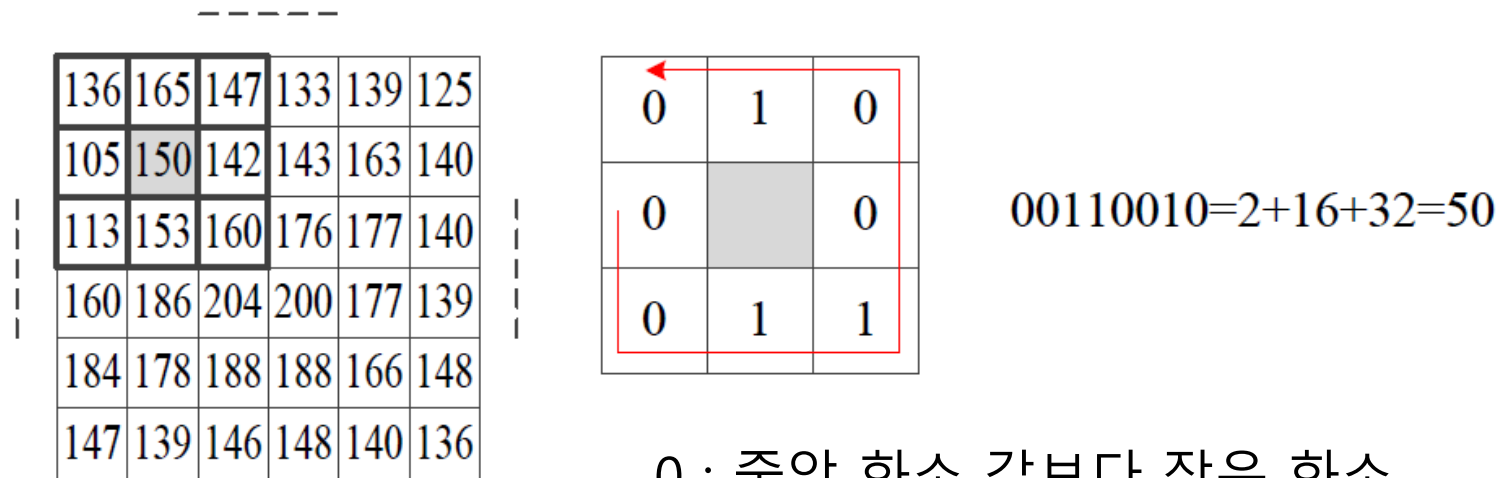


그림 6-17 LBP 계산

0 : 중앙 화소 값보다 작은 화소

1 : 중앙 화소 값보다 큰 화소

6.4.2 지역 관계 기술자

■ 지역 삼진 패턴 (LTP, Local Ternary Pattern)

- 화소 값이 p 라면, $p-t$ 보다 작으면 -1, $p+t$ 보다 크면 1, $[p-t, p+t]$ 사이면 0을 부여
- 두 개의 LBP로 분리
- 모든 화소를 가지고 히스토그램 구성

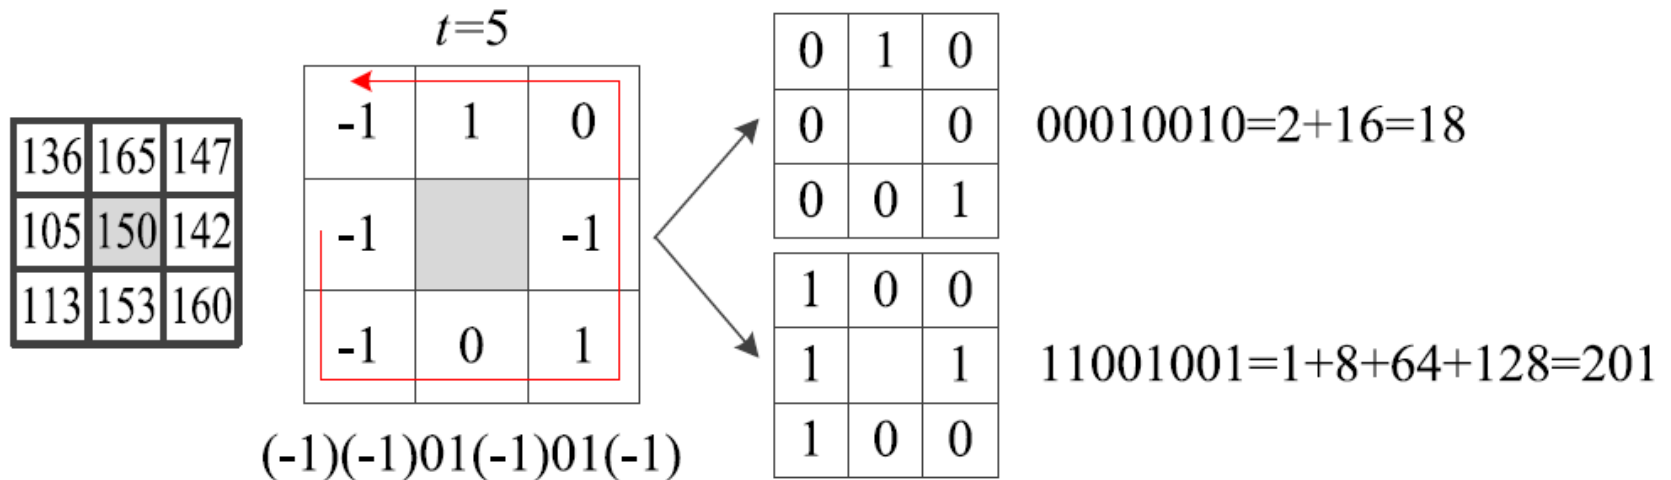


그림 6-18 LTP 계산

6.4.2 지역 관계 기술자

■ LBP와 LTP의 확장

- 조명 변환에 불변이나, 8이웃만 보면 스케일 변화에 대처하지 못함
- 다양한 이웃을 이용한 스케일 불변 달성




그림 6-19 LBP와 LTP가 사용하는 여러 가지 이웃

■ LBP와 LTP의 응용

- 예) 얼굴 검출, 사람 검출, 자연 영상에서 글자 추출 등

6.5 주성분 분석 (PCA, Principal Component Analysis)

■ 고차원 벡터를 저차원으로 축소

- 정보 손실을 최소화하는 조건



← 차원을 줄여서 표현하는 방법이 있을까?

그림 6-20 얼굴 영상(600×450)을 어떻게 기술할 것인가?

6.5.1 원리

6.5.2 알고리즘

6.5.1 원리

■ 원리

- 학습 집합 $X = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_n\}$ 로 변환 행렬 \mathbf{U} 를 추정
- $\mathbf{U} : d * D$ 차원 행렬, D 차원의 \mathbf{x} 를 d 차원의 \mathbf{y} 로 변환

$$\mathbf{y}^T = \mathbf{U}\mathbf{x}^T \quad (6.32)$$

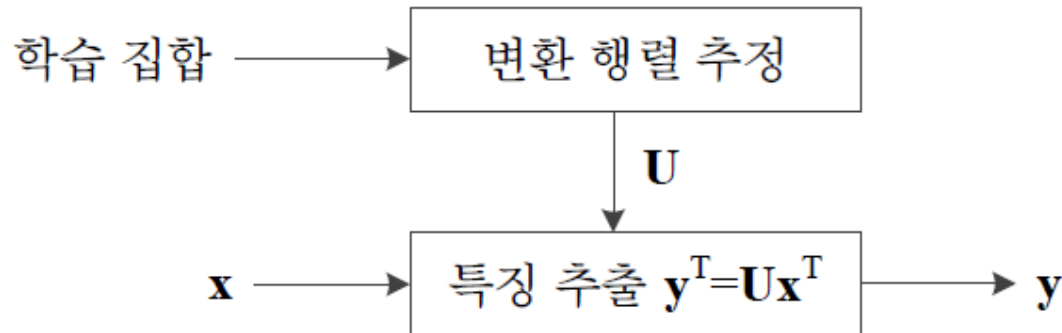


그림 6-21 주성분 분석의 처리 과정

6.5.1 원리

■ 차원 축소를 어떻게 표현하나?

- 축 \mathbf{u} 상으로 투영으로 표현 $\hat{\mathbf{x}} = \mathbf{u}\mathbf{x}^T$
- 그림 6-22는 2차원을 1차원으로 축소하는 상황

■ 정보 손실을 어떻게 표현하나?

- 정보란? 점들 사이의 거리나 상대적인 위치 등
- 어느 것의 정보 손실이 최소인가? → 직관적으로 판단하면 맨 오른쪽




그림 6-22 투영 변환을 적용하여 2차원 공간을 1차원 공간으로 축소

6.5.1 원리

■ PCA의 정보 손실 표현

- 원래 공간에 퍼져 있는 정도를 변환된 공간이 얼마나 잘 유지하는지 측정
- 이 수치를 변환된 공간에서 분산으로 측정

■ 최적화 문제

변환된 샘플들의 분산을 최대화하는 단위 벡터 \mathbf{u} 를 찾아라. (6.34)

- 그림 6-22에서 맨 오른쪽이 최적의 축인가?

6.5.1 원리

예제 6-2 변환 공간에서의 분산 계산

[그림 6-22]를 예제로 사용해 보자. 먼저 샘플 네 개를 [그림 6-22(a)]의 $\mathbf{u} = (0,1)$ 로 투영한다. 식 (6.33)을 적용하여 \mathbf{x}_i 를 \hat{x}_i 로 변환한 결과는 다음과 같다.

• 원래 샘플

$$\mathbf{x}_1 = (1, 2), \mathbf{x}_2 = (4, 2), \mathbf{x}_3 = (1, 4), \mathbf{x}_4 = (3, 4)$$

• $\mathbf{u} = (0,1)$ 로 투영 변환된 샘플

$$\hat{x}_1 = (0 \ 1) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 2, \hat{x}_2 = (0 \ 1) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 2, \hat{x}_3 = (0 \ 1) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = 4, \hat{x}_4 = (0 \ 1) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = 4$$

투영 변환으로 얻은 네 개의 점 2, 2, 4, 4의 평균은 3이고 분산은 1이다. 이제 [그림 6-22(c)]의 $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 로 투영해 보자.

• $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 로 투영 변환된 샘플

$$\hat{x}_1 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \frac{3}{\sqrt{2}}, \hat{x}_2 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \frac{6}{\sqrt{2}},$$

$$\hat{x}_3 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = \frac{5}{\sqrt{2}}, \hat{x}_4 = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \frac{7}{\sqrt{2}}$$

이들의 평균은 3.7123이고 분산은 1.0938이다. $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 이 $\mathbf{u} = (0,1)$ 보다 큰 분산을 만들어 준다. PCA가 볼 때 $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 이 더 좋은 것이다. 그렇다면 [그림 6-22]의 상황에서 $\mathbf{u} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ 보다 더 좋은 축이 있을까? 이것에 대한 답이 바로 식 (6.34) 문제의 해이다.

6.5.2 알고리즘

■ 최대화 문제

$$\hat{x}_i, \ 1 \leq i \leq n \text{의 평균 } \bar{\hat{x}} = \frac{1}{n} \sum_{i=1}^n \hat{x}_i = \frac{1}{n} \sum_{i=1}^n \mathbf{u} \mathbf{x}_i^T = \mathbf{u} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i^T \right) = \mathbf{u} \bar{\mathbf{x}}^T \quad (6.35)$$

$$\hat{x}_i, \ 1 \leq i \leq n \text{의 분산 } \hat{\sigma} = \frac{1}{n} \sum_{i=1}^n (\hat{x}_i - \bar{\hat{x}})^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2 \quad (6.36)$$

식 (6.36)의 분산 $\hat{\sigma}$ 을 최대화하는 \mathbf{u} 를 찾아라. (6.37)

■ \mathbf{u} 가 단위 벡터라는 조건을 포함시키면,

$$L(\mathbf{u}) = \frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2 + \lambda (1 - \mathbf{u} \mathbf{u}^T) \text{를 최대화하는 } \mathbf{u} \text{를 찾아라.} \quad (6.38)$$

최대 혹은 최소값

Lagrange Multipliers

constraint

6.5.2 알고리즘

- 도함수를 구하고, 도함수를 0으로 두고 정리하면,

$$\begin{aligned}\frac{\partial L(\mathbf{u})}{\partial \mathbf{u}} &= \partial \left(\frac{1}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T)^2 + \lambda (1 - \mathbf{u} \mathbf{u}^T) \right) / \partial \mathbf{u} \\ &= \frac{2}{n} \sum_{i=1}^n (\mathbf{u} \mathbf{x}_i^T - \mathbf{u} \bar{\mathbf{x}}^T) (\mathbf{x}_i - \bar{\mathbf{x}}) - 2\lambda \mathbf{u} \\ &= 2\mathbf{u} \left(\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})^T (\mathbf{x}_i - \bar{\mathbf{x}}) \right) - 2\lambda \mathbf{u} \\ &= 2\mathbf{u} \Sigma - 2\lambda \mathbf{u} \\ &= 2\Sigma \mathbf{u}^T - 2\lambda \mathbf{u} = 0\end{aligned}$$

← Σ 는 훈련 집합의 공분산 행렬

$\Sigma \mathbf{u}^T = \lambda \mathbf{u}^T$ 이럴 수가!!! Lagrange Multiplier에서 출발했는데,
cf) $A \cdot \mathbf{v} = \lambda \cdot \mathbf{v}$ eigen value로 치환되다니.. 심지어 표기도 똑같은 λ

- 식 (6.39)의 의미

이제까지 얻은 것을 정리해 보면 아주 단순하다. 우선 학습 집합의 공분산 행렬 Σ 를 구한다. 그런 다음 Σ 의 고유 벡터를 계산하면 그것이 바로 최대 분산을 갖는 \mathbf{u} 가 된다는 것이다.

6.5.2 알고리즘

예제 6-3 최대 분산을 갖는 축 계산

[그림 6-22]에 다시 주목해 보자. $X = \{(1, 2), (4, 2), (1, 4), (3, 4)\}$ 의 공분산 행렬 및 행렬의 고유값과 고유 벡터는 다음과 같다.

• 공분산 행렬 : $\Sigma = \begin{pmatrix} 1.688 & -0.250 \\ -0.250 & 1.000 \end{pmatrix}$

• 고유값과 고유 벡터 :

$$\lambda_1 = 1.7688, \mathbf{u}_1 = (0.9510, -0.3092)$$

$$\lambda_2 = 0.9187, \mathbf{u}_2 = (-0.3092, -0.9510)$$

두 개의 고유 벡터 중에 고유값이 큰 \mathbf{u}_1 을 선택한다. 이 \mathbf{u}_1 에 네 점을 투영한 결과는 다음과 같다.

• $\mathbf{u}_1 = (0.9510, -0.3092)$ 로 투영된 특징 벡터 :

$$\hat{x}_1 = (0.9510 \quad -0.3092) \begin{pmatrix} 1 \\ 2 \end{pmatrix} = 0.3326, \quad \hat{x}_2 = (0.9510 \quad -0.3092) \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 3.1856$$

$$\hat{x}_3 = (0.9510 \quad -0.3092) \begin{pmatrix} 1 \\ 4 \end{pmatrix} = -0.2858, \quad \hat{x}_4 = (0.9510 \quad -0.3092) \begin{pmatrix} 3 \\ 4 \end{pmatrix} = 1.6162$$

투영 변환된 점들의 평균은 1.2122이고 분산은 1.7688이다. [예제 6-2]에서 구한 값과 비교해 보자. [예제 6-2]에서는 대각선 축으로 투영한 경우 분산이 1.0938이었다. PCA로 찾은 \mathbf{u}_1 축이 더 큰 분산을 가지며, 이 축은 최적으로 더 좋은 축은 없다. [그림 6-23]은 PCA로 찾은 축으로 투영한 결과를 보여준다. [그림 6-22(c)]와 눈대중으로 비교해 보기 바란다.




그림 6-23 PCA로 구한 최적의 축

공분산 행렬

$$\Sigma = Cov(X)$$

$$= \begin{bmatrix} E(X_1 - \mu_1)^2 & E(X_1 - \mu_1)(X_2 - \mu_2) \\ E(X_2 - \mu_2)(X_1 - \mu_1) & E(X_2 - \mu_2)^2 \end{bmatrix}$$

$$\Sigma = Cov(X) = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$$

6.5.2 알고리즘

■ D 차원을 d 차원으로 축소

- 지금까지는 D 차원을 1차원으로 축소함
- 공분산 행렬 Σ 는 $D \times D$ 이므로, D 개의 고유 벡터가 있음
 - 이들은 서로 수직인 단위 벡터, 즉 $\mathbf{u}_i \mathbf{u}_i = 1$ 이고 $\mathbf{u}_i \mathbf{u}_j = 0, i \neq j$
- 고유값이 큰 순서대로 상위 d 개의 고유 벡터 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d$ 를 선택하고 식 (6.40)에 배치 (\mathbf{U} 는 $d \times D$, \mathbf{u} 는 $1 \times D$)

$$\mathbf{U} = \begin{pmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_d \end{pmatrix} \quad (6.40)$$

■ \mathbf{U} 를 이용한 차원 축소

$$\mathbf{y}^T = \mathbf{U} \mathbf{x}^T \quad (6.41)$$

(\mathbf{U} 는 $d \times D$, \mathbf{x} 는 $1 \times D$, \mathbf{x}^T 는 $D \times 1$, \mathbf{y}^T 는 $d \times 1$, \mathbf{y} 는 $1 \times d$)

6.6 얼굴 인식 : 고유 얼굴

■ 컴퓨터 비전에서 PCA의 응용 사례

- 기술자 추출 : PCA-SIFT, GLOH 등
- 가장 혁신적인 응용 → 얼굴 인식

■ 평균 얼굴

$$f_{av} = \frac{1}{n} \sum_{i=1}^n f_i \quad (6.42)$$
$$f_i(y, x), \quad 0 \leq y \leq M-1, \quad 0 \leq x \leq N-1$$




그림 6-24 얼굴 데이터베이스와 평균

6.6 얼굴 인식 : 고유 얼굴

■ 얼굴 영상에 PCA 적용

- 영상 f_i 를 벡터 형태로 변환 (벡터의 차원 $D=MN$) : 행 우선으로 재배치(2차원을 1차원으로)

$$\mathbf{x}_i = (f_i(0,0), f_i(0,1), f_i(0,2), \dots, f_i(0, N-1), f_i(1,0), f_i(1,1), \dots, f_i(M-1, N-1)) \quad (6.43)$$

- n 개의 얼굴 영상으로 구성된 학습 집합 $X=\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 을 입력으로 5절의 PCA를 적용
- 이렇게 얻은 고유 벡터 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d$ 를 고유 얼굴(eigen face)이라 부름
- 이들에 (6.43)을 역으로 적용(1차원을 2차원으로)하여 영상 형태로 바꾸면, 그림 6.25




그림 6-25 여섯 개의 고유 얼굴(오른쪽으로 갈수록 고유값이 작아짐)

- 고유 얼굴이 얼굴 형태를 띠는 이유는?

6.6 얼굴 인식 : 고유 얼굴

■ 고유 얼굴의 활용: 얼굴 영상 압축 [Sirovich87]

알고리즘 6-5 고유 얼굴을 이용한 얼굴 영상 표현

입력: 영상 $f(j, i)$, $0 \leq j \leq M-1$, $0 \leq i \leq N-1$, 변환 행렬 \mathbf{U} // \mathbf{U} 는 $d \times MN$ 행렬

출력: 얼굴 영상 표현 \mathbf{y} // \mathbf{y} 는 d 차원

- 1 f 를 식 (6.43)을 이용하여 벡터 \mathbf{x} 로 변환한다.
- 2 식 (6.41)을 이용하여 \mathbf{y} 를 구한다.

■ 역 변환으로 복원 가능

$$\mathbf{x}'^T = \mathbf{U}^{-1} \mathbf{y}^T \quad (\mathbf{U}^{-1} \text{는 } D(MN) * d, \mathbf{y}^T \text{는 } d * 1, \mathbf{x}'^T \text{는 } D * 1, \mathbf{x}' \text{는 } 1 * D)$$




그림 6-26 $d=6$ 으로 압축한 후 복원한 얼굴 영상

그림 6-24와 비교

6.6 얼굴 인식 : 고유 얼굴

■ 고유 얼굴의 활용: 얼굴 인식 [Turk91b]

- PCA로 변환한 벡터 \mathbf{y}_i 를 모델로 사용 : $Y = \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n\}$
- 테스트 영상 f 가 입력되면 PCA로 \mathbf{y} 를 구한 후, Y 에서 가장 가까운 벡터를 찾아 그 부류로 분류

■ 고유 얼굴 활용 시 주의 점

- 얼굴을 찍은 각도와 얼굴 크기, 영상 안에서의 얼굴 위치, 조명이 어느 정도 일정해야 함.
- 영상마다 다르고 그 변화가 클수록 성능이 떨어짐
- Turk와 Pentrland의 연구 결과
 - 조명에 변화를 준 경우 96%, 각도에 변화를 준 경우 85%, 크기에 변화를 준 경우 64%의 정인식률을 얻음

6.6 얼굴 인식: 고유 얼굴

예제 6-4 고유 얼굴을 이용한 얼굴 인식

[그림 6-24]의 여섯 개 영상에 [알고리즘 6-5]를 적용하면 다음과 같은 벡터 $y_1 \sim y_6$ 을 얻는다.

$$y_1 = (-268.30, 76.52, -30.31, 51.29, 119.69, 0.00)$$

$$y_2 = (274.98, -258.59, 58.96, -109.32, 37.86, 0.00)$$

$$y_3 = (-240.15, 100.12, -201.25, -238.24, -64.99, 0.00)$$

$$y_4 = (-246.11, -4.44, 306.29, 99.12, -41.39, 0.00)$$

$$y_5 = (471.28, 243.09, 27.82, 40.17, -5.06, 0.00)$$

$$y_6 = (8.29, -156.70, -161.52, 156.97, -46.09, 0.00)$$

[그림 6-27]은 테스트 얼굴 영상으로, [그림 6-24]에 나타난 여섯 사람 중 두 사람에게 해당하는 새로운 얼굴 영상이다. 이들을 각각 f_{test1} 과 f_{test2} 라 하고, [알고리즘 6-5]에 입력하면 다음과 같은 벡터를 얻는다.

$$y_{\text{test1}} = (-285.04, 113.83, -79.42, 32.89, 92.32, 0.00)$$

$$y_{\text{test2}} = (474.74, 211.56, 108.89, 134.94, 24.90, 0.00)$$

이들 두 벡터와 앞의 여섯 개 벡터 $y_1 \sim y_6$ 과의 거리를 계산하면 y_{test1} 은 y_1 과 가장 가깝고 y_{test2} 는 y_5 와 가장 가깝다. 두 개의 테스트 영상을 옳게 인식하였나?





그림 6-27 테스트 얼굴 영상